



Лекция 2



**Работа с данными.
Основные операции над
переменными (столбцами)
и наблюдениями
(строками).**

Данные в *STATISTICA* организованы в виде электронной таблицы. Таблица с исходными данными (таблицы хранятся в файлах с расширением *.sta) является одним из типов документа в системе *STATISTICA* (другие типы документов – электронная таблица с результатами анализа, график, отчет).

Каждый тип документа выводится в своем окне в рабочей области системы. Как только это окно становится активным, изменяется панель инструментов и меню. В нем появляются команды, доступные для этого типа документов.

Для работы с электронными таблицами исходных данных существует большое количество операций, которые доступны при помощи выпадающих и контекстных меню и из панели инструментов. Перечислим основные из них.

1. Операции, которые изменяют структуру электронной таблицы. Это операции добавления, удаления, копирования и перемещения переменных и наблюдений из электронной таблицы. Операции по заданию спецификаций (имен, форматов и т. д.) для переменных и наблюдений.

2. Большое количество операций с выделенным блоком значений. Эти операции не меняют структуру файла, а изменяют только значения данных в таблице. Они включают

стандартные операции с Буфером обмена, например, операции вырезать, копировать, вставить, очистить и др. Часть операций с блоком значений ориентирована на специфику статистической обработки, например: транспонирование блока, заполнение случайными значениями, стандартизация значений в блоках, вычисление основных статистических характеристик блока значений, визуализация значений, блока значений и др.

3. Операции, реализованные при помощи метода Drag and Drop (перетащить – отпустить), включая операции по копированию, перемещению и автозаполнению блока и др.

4. Операции перекодировки и ранжирования переменных.

Программа поддерживает большое количество методов обмена с данными из других приложений. При этом реализованы способы ввода данных с использованием:

- буфера обмена;
- механизма динамического обмена данными *DDE* – динамического обмена данными *Windows*;
- средств импорта данных, которые позволяют импортировать данные практически из любой базы данных.

Легко, без специальных средств можно из STATISTICA открыть таблицу в Excel, либо скопировать данные в Excel и вставить в таблицу STATISTICA, но отдельно значения в ячейках таблицы и названия переменных.

Язык программирования *STATISTICA Visual Basic* позволяет создавать дополнительные приложения, реализующие как простые преобразования данных, так и сложные вычислительные процедуры.

В *STATISTICA* можно записать макросы, которые автоматизируют повторяющиеся шаги или используются для автоматического создания программ.

В *STATISTICA* используется подмножество языка программирования *SQL* (язык запросов к базам данных) для задания критериев импорта записей из баз данных.



Структура электронной таблицы.

Statistica - Таблица мед. расходы

Calibri 11 B I U

Файл Правка Вид Вставка Формат Анализ Добыча Данных Графика Сервис Данные Окно Справка


Создать... Ctrl+N
 Открыть... Ctrl+O
 Открыть папку примеров...
 Импортировать изображения...
 Закрыть
 Сохранить Ctrl+S
 Сохранить как... F12
 Сохранить как PDF...
 Сохранить Проект...
 Сохранить Проект как...
 Открыть Проект...
 Закр^ыть Проект
 SharePoint
 Внешние данные
 Добавить в Рабочую книгу
 Добавить в отчёт
 Диспетчер вывода...
 Параметры печати...
 Предварительный просмотр
 Печать... Ctrl+P
 Свойства...
 Последний файл
 Выход

сходы (8v * 1338с)


2	3	4	5	6	7	8
Индекс ма	Количество детей	Пол	Курильщик	Регион проживания	Расходы	Выборки
27,9		0 female	yes	southwest	16884,924	Обучающа
33,77		1 male	no	southeast	1725,5523	Обучающа
33		3 male	no	southeast	4449,462	Обучающа
22,705		0 male	no	northwest	21984,4706	Обучающа
28,88		0 male	no	northwest	3866,8552	Обучающа
25,74		0 female	no	southeast	3756,6216	Обучающа
33,44		1 female	no	southeast	8240,5896	Тестовая
27,74		3 female	no	northwest	7281,5056	Обучающа
29,83		2 male	no	northeast	6406,4107	Обучающа
25,84		0 female	no	northwest	28923,1369	Обучающа
26,22		0 male	no	northeast	2721,3208	Обучающа
26,29		0 female	yes	southeast	27808,7251	Обучающа
34,4		0 male	no	southwest	1826,843	Обучающа
39,82		0 female	no	southeast	11090,7178	Обучающа
42,13		0 male	yes	southeast	39611,7577	Обучающа
24,6		1 male	no	southwest	1837,237	Обучающа
30,78		1 female	no	northeast	10797,3362	Обучающа
23,845		0 male	no	northeast	2395,17155	Обучающа
40,3		0 male	no	southwest	10602,385	Обучающа
35,3		0 male	yes	southwest	36837,467	Обучающа
36,005		0 female	no	northeast	13228,847	Обучающа
32,4		1 female	no	southwest	4149,736	Тестовая
34,1		0 male	no	southeast	1137,011	Обучающа

23 18

Исходные данные организованы в виде таблицы, для создания которой следует воспользоваться на панели инструментов иконкой Создать, в появившемся окне перейти на вкладку Таблица и указать параметры создаваемой таблицы. После нажатия на ОК таблица будет создана




Изображения таблиц в англоязычной версии и русскоязычной версии



The screenshot shows a spreadsheet window with a blue title bar. The title bar text is "Data: Spreadsheet1* (5v by 10c)". The spreadsheet has a grid with 10 rows and 5 columns. The first row is a header row with cells containing "1", "2", "3", "4", and "5". Below these are five rows of data, each with a row number in the first column (1-5) and four empty cells.

	1	2	3	4	5
1					
2					
3					
4					
5					



The screenshot shows a spreadsheet window with a light blue title bar. The title bar text is "Данные: Таблица данных1 (10v * 10c)". The spreadsheet has a grid with 10 rows and 5 columns. The first row is a header row with cells containing "1", "2", "3", "4", and "5". Below these are five rows of data, each with a row number in the first column (1-5) and four empty cells.

	1	2	3	4	5
1					
2					
3					
4					
5					

Электронная таблица состоит из строк и столбцов. В отличие от обычных электронных таблиц, в которых строки и столбцы равноправны, в *STATISTICA* они имеют разные смысловые значения. При этом столбцы таблицы называются *Variables* (переменные), а строки – *Cases* (случаи, наблюдения).

Каждая переменная имеет свое имя, формат и другие атрибуты (которые называются спецификацией переменной), задаваемые пользователем. Переменная представляет собой наблюдаемую величину. Результаты наблюдений записываются в строках таблицы – наблюдениях.

Нулевой столбец в таблице при необходимости может содержать имена случаев. Ими могут быть либо даты наблюдений, либо какие-то другие имена, обычно естественно возникающие в конкретной задаче, например, имена опрашиваемых, при сборе данных социологического исследования, поэтому в качестве имен случаев *STATISTICA* позволяет использовать либо число, либо текстовое значение или значение даты. Для задания имен следует подвести курсор к левой части нулевого столбца соответствующей строки, чтобы он принял вид прицела и щелкнув по полю, набрать или вставить текст с именами наблюдений

Электронная таблица с исходными данными в *STATISTICA* называется *Spreadsheet*. Электронные таблицы с исходными данными хранятся в файлах с расширением **.sta*.

Окно спецификации

Открывается, если дважды нажать на поле с именем переменной

Формат Анализ Добыча Данных Графика Сервис Данные **Окно** Справка

Добавить в Рабочую книгу Добавить в Отчет Добавить в MS Word

В И U Шрифт Цвет Заполнение Свойства

Данные: Таблица данных1* (10v * 10с)

	1 Рост	2 Вес	3 Пер3
Иванов	1,75	82,5	
Петров	1,8	74,3	
Сидоров	1,68	65	
4			
5			
6			
7			
8			
9			
10			

Переменная 3 ? X

А Arial 10 В И U x_2 x^2 A

Имя: Индекс массы тела Тип: Вещественный OK

Шкала измерения: Авто Ширина: 8 Отмена

☐ Исключённые ☐ Ярлык ☐ Состояние Код ПД: -999999998 << >>

Формат отображения

Общий Число Дес. разряды: 2

Дата
Время
Научный
Денежный
Проценты
Дробный
Другой

1000,00; -1000,00
1 000,00; -1 000,00
1000,00; (1000,00)
1 000,00; (1 000,00)

Все спецификации...
Текстовые метки...
Значения/Статистики...
Свойства...
[Наборы]...

Длинное имя (метка или формула с Функциями): ☒ Просмотр функций

$$=(v2/v1)**2$$

Метки могут содержать любой текст. В формулах используйте имена переменных или обозначения v1, v2, ...; v0 обозначает номер наблюдения.
Пример: (a) = mean(v1:v3, sqrt(v7), AGE) (b) = v1+v2; комментарий (после:)

В электронной таблице *Spreadsheet* пользователь может задать спецификации переменных:

- имя переменной
- формат отображения (например, число десятичных знаков или формат значений даты или времени);
- определенные значения, которые нужно пропускать при расчетах (т.е. коды пропущенных данных);
- длинные имена переменных и комментарии;
- длинные метки и комментарии для отдельных значений (см. ранее);
- формулы, которые можно использовать для задания, перекодирования или преобразования каждой переменной;

Задание:

1. Набрать таблицу в Excel подгруппы студентов с указанием роста, веса. Создать аналогичную таблицу в STATISTICA двумя способами: простым копированием ячеек таблицы, имен студентов и названий столбцов (рост, Вес); открыв таблицу из STATISTICA
2. В STATISTICA добавить пол, дату рождения, цвет глаз, место учебы – Краснодар, другой город. Пол и дату рождения ввести воспользовавшись информацией из 3 последующих слайдов 13 – 15.
3. Допустить ошибки в росте, или весе и идентифицировать их при помощи процедуры **Проверка данных** из меню **Данные**

Значения дат в *STATISTICA* хранятся в юлианском формате, как целые числа, представляющие число дней, прошедших с 1 января 1900 г. Например, дата, отображаемая как 1/21/1968, в юлианском формате представляет число 24858; при этом десятичные знаки интерпретируются как время. Хранящиеся таким образом значения дат можно использовать в любой процедуре анализа. В то же время в отчетах и на графиках можно отображать даты в общепринятом формате (например, для отметок на шкале). Юлианские значения дат в таблице исходных данных можно отображать как в числовом (юлианском) формате, так и в одном из заранее заданных форматов отображения дат.

При работе с реальными данными часто приходится иметь дело с ситуациями, когда часть данных не была по каким-либо причинам измерена. В этом случае в соответствующую ячейку электронной таблицы не заносится никакое значение. Ячейка остается пустой. Однако при внутреннем хранении данных *STATISTICA* приписывает всем пустым ячейкам — пропущенным наблюдениям данных, некоторый специальный код *Missing Data Code* (код пропущенных данных). Код пропущенных значений устанавливается в спецификации переменной. Значение этого кода по умолчанию равно -9999.

Выбор формата даты

The screenshot shows the 'Переменная 4' (Variable 4) dialog box in Microsoft Excel. The 'Имя' (Name) field contains 'Дата рождения' (Date of birth). The 'Тип' (Type) is set to 'Вещественный' (Numerical). The 'Шкала измерения' (Measurement scale) is 'Авто' (Auto). The 'Код ПД' (PD Code) is '-999999998'. The 'Формат отображения' (Display format) section is active, showing a list of date formats. The 'Дата' (Date) category is selected, and the '17/03/10' format is highlighted. The 'Длинное имя' (Long name) field is empty. The 'Просмотр функций' (View functions) checkbox is checked.

Переменная 4

А Arial 10 В I U x₂ x² A

Имя: Дата рождения Тип: Вещественный OK

Шкала измерения: Авто Ширина: 8 Отмена

☐ Исключённые ☐ Ярлык ☐ Состояние Код ПД: -999999998 << >>

Формат отображения

Общий	3/17/10
Число	03/17/2010
Дата	17-Mar-10
Время	17-Mar
Научный	Mar-2010
Денежный	17/03/10
Проценты	2010/03/17
Дробный	Формат Windows
Другой	

Все спецификации...
Текстовые метки...
Значения/Статистики...
Свойства...
[Наборы]...



Длинное имя (метка или формула с Функциями): ☒ Просмотр функций

Длина: Введите 0, чтобы посчитать минимальную длину текстовой переменной
Метки: Используйте любой текст. Formulas: Должна начинаться со знака =.
Используйте имена переменных, или номера V1, V2, ..., V0 это номер строки.
Примеры: (a) = mean(v1:v3, sqrt(v7), AGE) (b) = v1+v2; comment (after);
В случае конфликтов, имена переменных имеют больший приоритет, чем текстовые значения переменных.


Задание: добавить столбец с сегодняшней датой и вычислить количество прожитых дней

Механизм двойной записи

Для удобной работы с переменными, принимающими текстовые значения, реализован так называемый механизм двойной записи. Согласно этому соглашению каждому текстовому значению переменной ставится в соответствие некоторое число. Таким образом, устанавливается соответствие вида *число = текстовое значение*. Оно может быть установлено автоматически (самой системой при вводе данных) или определено пользователем.



При работе с данными всегда можно переключиться с текстовой на числовую форму просмотра исходных данных. Наличие описанного механизма двойной записи позволяет удобно вводить текстовые значения, выполнять необходимые преобразования и, кроме того, любой статистический анализ над текстовыми переменными так, как если бы они принимали числовые значения.



а Серви

Показать/Скрыть текстовые метки


к книгу ▾ Добавить в Отчет ▾ Добавить в MS Word ▾ Добавить в Рабочую область ▾

4 Пол	5 Курильщик	6 Регион проживания	7 Расходы	8 Выбор
1		1	16884,924	
2	0	2	1725,5523	
2	0	2	4449,462	
2	0	3	21984,4706	
2	0	3	3866,8552	
1	0	2	3756,6216	
1	0	2	8240,5896	




**Основные операции над
переменными и
наблюдениями.**

Операции над переменными доступны либо через меню **Данные (Data)** – команда **Переменные**, либо через контекстное меню, щелкнув правой кнопкой мыши на имени переменной в таблице данных



Операция над переменной через контекстное меню

Для активации щелкнув левой кнопкой мыши в ячейке с названием, нажимаем на правую кнопку




Для преобразования данных в столбце можно воспользоваться формулами в таблице исходных данных. Двойной щелчок на имени преобразуемой переменной открывает диалоговое окно спецификаций переменной, в котором формулу преобразования или перекодировки можно ввести непосредственно в поле **Long name (Label or formula with Functions)** (длинное имя (метка или формула с функцией)).

Формулы должны начинаться с символа “=”. В противном случае программа не определит, что введенный текст является формулой. Переменные вызываются по именам или по номерам, например, $v1$, $v2$,...

Для выражений, содержащих условия преобразования, можно использовать логический оператор. Чтобы пересчитать значения переменной согласно введенной формуле, надо нажать на **ОК**. Откроется окно, в котором будет предложено подтвердить команду **Recalculate the variable now** (пересчитать переменную сейчас, если формула записана верно).

Команда **Recalculate** (пересчет, см. слайд 17 иконку на панели, или 19 команду) предназначена для пересчета значений переменных, которые связаны при помощи формул. Имеются возможности установить опцию автоматического пересчета значений переменной при изменении данных в электронной таблице. Можно пересчитывать не все значения переменной, а лишь некоторое подмножество случаев. Для этого в рамке Подмножество необходимо указать диапазон случаев. Команда также доступна при помощи кнопки на панели инструментов **X** = ?



Задание:

1. После столбцов Рост и Вес добавить столбец ИМТ , в поле *Длинное имя* задать формулу для вычисления ИМТ используя обозначения через v: $\text{ИМТ} = \text{вес (в кг)} / \text{рост}^2 \text{ (в м)}$
2. В какой либо строке изменить рост, или вес и при помощи команды **Recalculate** пересчитать ИМТ.
3. Сделать тоже самое в автоматическом режиме

При помощи команды **Recode Variables** (перекодировать переменные) можно перекодировать значения переменной, при этом исходные значения переменной заменяются новыми текстовыми значениями.

Задание: Перекодировать ИМТ в предположении, что ИМТ это v10

Перекодировать значения переменной 27: КС


Категория	Новое значение
Категория 1 Включить если: v10 <= 18,5	☒ значение: дефицит веса ☐ код ПД
Категория 2 Включить если: v10 > 18,5 and v10 <=25	☒ значение: норма ☐ код ПД
Категория 3 Включить если: v10 > 25	☒ значение: избыточный вес ☐ код ПД
Категория 4 Включить если:	☒ значение: ☐ код ПД

Другие
Если условия не выполняются, значение равно:
☐ код ПД
☐ значение:
☒ не изменять

OK
Отмена
Очистить все
Открыть...
Сохранить...
Переменная...

Команда **Rank** (ранжировать) (рис. 2.6) позволяет ранжировать одну или более переменных. Содержимое столбца будет заменено рангами значений.

Для сохранения исходных значений столбца (переменной) надо сделать копию переменной и произвести ее ранжирование.



Рассмотрим назначение функциональных кнопок диалогового окна:

- **Переменные** позволяет выбрать переменные для ранжирования;
- **Наблюдения** предназначена для выбора набора случаев, которые надо ранжировать;

– **Вес** можно задать вес выделенных ранее переменных с помощью другой переменной таблицы исходных данных.

Рассмотрим функциональное назначение полей выбора основных опций ранжирования:

– **Присвоить ранг 1.** Значения можно ранжировать по возрастанию, т.е. *smallest value* (наименьшее значение) начинается с 1. Или по убыванию, т.е. *largest value* (наибольшее значение) начинается с 1;

– **Ранги для совпадающих значений.** Опция *Mean* (средний) означает, что рангам совпадающих значений присваивается средний из этих рангов. Опция *Sequential* (последовательный) означает, что каждое совпадающее значение ранжируется последовательно в порядке их появления в столбце. Опции *Low* (низший), *High* (высший) означают, что каждому совпадающему значению присваивается соответственно наименьший или наивысший из рангов совпадающих значений;


– **Типы рангов.** Опция *Regular* (обычный) – диапазон ранжирования от 1 до n (n – число случаев в таблице). Опция *Fractional* (дробный) – диапазон ранжирования от 0 до 1. Опция *Fractional as %* (дробный в %) – ранги являются процентным соотношением, основанным на дробном ранжировании значений переменной.

Командой **Standardize** (стандартизация) все значения выбранных переменных заменяются на стандартизованные значения, вычисляемые следующим образом:

$$\text{стандартное значение} = \\ = (\text{исходное значение} - \text{среднее}) / \text{стандартное отклонение}.$$

В открывшемся диалоговом окне надо выбрать переменные для стандартизации, а также подмножество наблюдений для стандартизации (по умолчанию выбираются все наблюдения) и задать веса для наблюдений. Задание весов эквивалентно тому, что каждое наблюдение используется при вычислении среднего и стандартного отклонения несколько раз, пропорционально весу.

Команда **Подмножество** позволяет из исходной таблицы данных создать меньшую таблицу. Если нажать на кнопку **Переменные** появится список переменных в котором надо указать переменные новой таблицы.



Если нажать на кнопку **Наблюдения** появится окно предназначенное для выбора подмножества случаев для анализа. Доступ к этому окну организован в каждом модуле программы. Кнопка **select cases** расположена в правой части стартовых окон модулей



Условия выбора наблюдений в Таблице данных



☒ Задать условия выбора



Просмотр переменных:

Очистить все

OK

Отмена



Открыть...



Сохранить...

Включить наблюдения в Анализ/Графики

☐ Все наблюдения

☒ Заданные:

По выражению:

Функции

Номера наблюдений:

Исключить наблюдения из Анализа/Графика

Удовлетворяющие условию:

Функции

Номера наблюдений:

Номера наблюдений:

Введите номера наблюдений, включаемые или исключаемые из Анализа, или диапазоны.
Например: 1, 3, 5-12

Удовлетворяющие
условию:

Используйте операторы, функции, синтаксис, стандартные для электронных таблиц.
Допускается использовать номера переменных (v1, v2...).
Например: (a) v1=0 OR age>18 (b) gender='MALE' AND v4<>(v5+v6)

В случае совпадения имена переменных имеют более высокий приоритет, чем текстовые значения. Для указания на текстовый тип лексемы добавьте символ \$.
Например: "Значение"\$.

Если установить флажок на **Задать условия выбора**, то будут активны опции окна. В рамках **Включить наблюдения в Анализ**, **Исключить наблюдения из Анализа** задаются условия в соответствии с которыми наблюдения будут включены, или исключены из наблюдения. В полях **По выражению**, **Удовлетворяющие условию** задаются при помощи знаков равенства, $>$, $<$, $\geq$, $\leq$, логических операторов условия включения, или исключения наблюдений в подмножество

Если проводится анализ по одной переменной, то условия выбора случаев могут быть произведены по другой переменной. Например, стандартизуется переменная $v1$, а условие выбора случаев имеет вид $v2 \geq 25$ или $v0 \leq 8$ (напомним, что $v0$ означает номер наблюдения).

В поле **Номера наблюдений** можно просто перечислить номера случаев, которые либо включаются в анализ, либо не включаются. Например, $1:5$ означает, что в анализ включены (не включены) наблюдения 1-5; а $1; 3; 5$ означает, что в анализ включены (не включены) наблюдения 1, 3, 5. Номера можно перечислить просто через пробел.

Можно задавать сложные условия выбора при помощи логических операторов **AND** (и), **OR** (или), **NOT** (нет). При этом должны соблюдаться определенные правила. Можно ссылаться на переменную, используя либо ее номер (например, *v1, v5*), либо имя. Текстовые значения необходимо заключать в одиночные кавычки (например, *v5 – «есть»*), а сложные условия – в скобки.

Полный список доступных операторов следующий:

=	(равно)
#, <>, X	(не равно)
<	(меньше)
>	(больше)
<=	(меньше или равно)
>=	(больше или равно)
NOT, ~	(логическое отрицание)
AND, &	(логическое И)
OR	(логическое ИЛИ).

Примеры правильной записи правил отображены в нижней части окна