



Описательные статистики
Корреляционная матрица

Анализ данных желательно начинать с проверки данных, пытаясь выявить выбросы – нетипичные данные, которые могут быть ошибками сбора данных, их форматирования, передачи и т.д. Для этой цели можно использовать процедуру **Проверка данных** из меню **Данные**, либо модуль **Описательные статистики**. Но описательные статистики также нужны для общей характеристики данных, по которым проводится анализ. С понятиями описательных статистик ознакомимся, воспользовавшись одноименным модулем. Посчитаем описательные статистики для файла Страны мира, представленного на слайде.


	Крупнейшие страны мира по численности населения								
	1 1990г	2 1995г	3 2000г	4 Город 1995г	5 Нефть	6 Газ	7 Пром.	8 С/х	9 Услуги
Китай	1120	1121	1275	30,3	есть	есть	48	21	31
Индия	830	935	1010	26,8	нет	нет	30	29	41
США	250	263	250	76,2	есть	есть	26	2	72
Бразилия	150	162	170	78,2	нет	нет	37	14	49
Россия	289	149	146	73	есть	есть	38	7	55
Япония	124	125	126	77,6	нет	нет	38	2	60
ФРГ	80	82	82	86,5	нет	нет	38	2	60
Индонезия	180	198	215	35,4	есть	есть	42	17	41
Великобритания	57	57	69	89,5	нет	нет	32	2	66
Франция	56	58	59	72,8	нет	нет	27	2	2 71

В нем приведены некоторые экономические показатели 10 крупнейших стран мира по численности городского населения: общее число жителей (млн. чел.) на 1990, 1995, 2000 г.; доля (%) городского населения на 1995 г.; наличие крупных запасов нефти и газа (более 1,5 млрд. т); структура ВВП (%) в промышленности, сельском хозяйстве, сфере услуг.


Для запуска программы в верхнем меню **Statistics** (Анализ) надо выбрать команду **Basic Statistic/Tables** (Основные статистики и таблицы).



Откроется окно на вкладке Быстрый, воспользуемся кнопкой Переменные,



Укажем 3 последние в таблице количественные переменные, нажмем на ОК и перейдем на вкладку дополнительно, где приведены основные статистики, характеризующие случайные величины



Описательные статистики: Страны мира1

Переменные: Пром.-Услуги

Быстрый | Дополнительно | Робастность | Нормальность | Диаграммы | Categ. графики | Опции

Подробные описательные статистики Г1 Г2 Статистики: _____

Парам. положения

☒ N набл.

☐ % набл.

☒ Среднее

☐ Сумма

☒ Медиана

☐ Мода

☐ Геом. среднее

☐ Гармонич. среднее

Вариация, моменты

☒ Станд. откл.

☐ Доверит. интервал станд. откл.
Уровень: 95,00 %

☒ Коэффициент вариации

☐ Дисперсия

☒ Станд. ош. среднего

☒ Дов. инт. среднего
Уровень: 95,00 %

☒ Асимметрия

☐ Станд. ош. асимметрии

☒ Экссесс

☐ Станд. ош. эксцесса

Процентили, размахи

☒ Минимум и максимум

☒ Нижн., верхн. квартили

☐ Границы процентилей

☒ Первая: 10,00 % Вторая: 90,00 %

☐ Границы: 10 20 30 40 50 60 70 80 90

☐ Интервалы: 10

☒ Размах ☒ Квартильн. размах

Выбрать все Сброс

Сохранить как умолчания

OK

Отмена

Опции

По Группам

SELECT CASES

☐ Взвеш. момент

Ст. свободы

☒ B-1 ☐ N-1

Удаление ПД

☐ Построчное

☒ Попарное

Рассмотрим более подробно статистики, предусмотренные в этом модуле. Статистики, используемые в данном модуле, в основном очень просты. Применение тех или иных статистик определяется использованием шкал, в которых произведено измерение признаков исследуемых объектов.

Mean (среднее арифметическое) – показывает центральное положение (центр) переменной и рассматривается совместно с доверительным интервалом.

Доверительный интервал представляет интервал значений вокруг оценки, где с данным уровнем доверия находится «истинное» (неизвестное) среднее генеральной совокупности. Например, если среднее выборки равно 23, а нижняя и верхняя границы доверительного интервала с уровнем $p = 0,95$ равны соответственно 19 и 27, то можно заключить, что с вероятностью 95% интервал с границами 19 и 27 накрывает среднее **генеральной совокупности**.

Если установить больший уровень доверия, то интервал станет шире, поэтому возрастает вероятность, с которой он «накрывает» неизвестное среднее, и наоборот.

Квантиль, соответствующая вероятности p , это значение переменной, ниже которой находится p -я часть (доля) упорядоченной по возрастанию выборки выборки. Квантили, соответствующие вероятностям 0,25 и 0,75, называются соответственно *Lower & upper quartiles* (*нижней и верхней квартилью*; кварта – четверть).

Альтернативной оценкой среднего являются *median* (медиана) и *mode* (мода).

Медиана – это квантиль, соответствующая вероятности 0,5, т.е. это значение, которое разбивает выборку на две равные части по количеству элементов. Одна половина наблюдений лежит ниже медианы, вторая половина – выше. Если число наблюдений в выборке четно, то медиана вычисляется как среднее двух средних значений.

Нижняя квартиль, медиана, верхняя квартиль делят выборку на 4 равные части. Как правило, используется для оценки среднего, если переменная измерена в порядковой шкале.

Moda – это значение переменной, соответствующее наибольшей частоте появления переменной в выборке. Как правило, используется для оценки среднего, если переменная измерена в номинальной или порядковой шкале.

Std.dev. (стандартное отклонение) – это корень квадратный из суммы квадратов отклонений значений переменной от среднего значения, деленное на $n-1$.

Std.err.of mean (стандартная ошибка среднего) – это мера точности, с которой выборочное среднее оценивает истинное среднее генеральной совокупности. Равно стандартному отклонению, деленному на корень квадратный из объема выборки.

Variance (коэффициент вариации) – это отношение стандартного отклонения к среднему.

Minimum (минимум) или *Maximim* (максимум) – это соответственно минимальное или максимальное значение выборки.

Range (размах) – это разность между максимальным и минимальным значениями выборки.

Quartiles range (квартильный размах) равен разности значений верхней и нижней квартилей, т.е. это интервал, содержащий медиану, в который попадает 50% выборки.

Skewness (асимметрия) – это мера симметричности распределения. Если распределение симметрично, то асимметрия равна нулю, если асимметрия существенно отличается от 0, то распределение несимметрично. Нормальное и равномерное распределения абсолютно симметричны. Асимметрия распределения с длинным правым хвостом положительна. Если распределение имеет длинный левый хвост, то его асимметрия отрицательна.

Kurtosis (эксцесс) – мера остроты пика распределения. Если распределение нормальное, то эксцесс равен 0. Если эксцесс положителен, то пик заострен, если отрицателен, то пик закруглен.

Нажмем на кнопку **Подробные описательные статистики** на вкладке **Дополнительно**, или **Быстро**.

Переменная	Описательные статистики (Страны мира1)						
	N набл.	Среднее	Доверит. -95,000%	Доверит. 95,000%	Медиана	Минимум	Максим.
Пром.	10	35,60000	30,68765	40,51235	37,50000	26,00000	48,00000
С/х	10	9,80000	2,74407	16,85593	4,50000	2,00000	29,00000
Услуги	10	54,60000	44,71530	64,48470	57,50000	31,00000	72,00000

Переменная	Описательные статистики (Страны мира1)						
	Нижняя Квартиль	Верхняя Квартиль	Размах	Квартиль Размах	Ст.откл.	Кэф. Вар.	Станд. ошибки
Пром.	30,00000	38,00000	22,00000	8,00000	6,86699	19,2893	2,171533
С/х	2,00000	17,00000	27,00000	15,00000	9,86351	100,6481	3,119117
Услуги	41,00000	66,00000	41,00000	25,00000	13,81786	25,3074	4,369592

Переменная	Описательные статистики (Страны мира1)	
	Асимметрия	Эксцесс
Пром.	0,201554	-0,360406
С/х	0,945905	-0,345553
Услуги	-0,361939	-0,973467

Вычисление медианы для Пром.:

26, 27, **30**, 32, **37, 38**, 38, **38**, 42, 48

$(37+38)/2=37,5$

Вычислим описательные статистики для стран не имеющих и имеющих нефть (КНОПКА SELECT CASES, v5=0, v5=1).

Условия выбора наблюдений Анализа/Графика

Используются условия выбора наблюдений Анализа/Графика

Задать источник условий выбора...

☒ Использовать условия выбора

Просмотр переменных: Очистить все

Включить наблюдения

☐ Все наблюдения

☒ Заданные:

По выражению: v5=0

Функции

Номерами:

Исключить наблюдения

Заданные условием:

Функции

Номерами:

Номера наблюдений: Введите номера наблюдений или их диапазоны. Пример: 1, 3, 5-12

Условия: Используйте стандартные для электронных таблиц операторы, функции, синтаксис:
Используйте имена переменных или v1, v2... v0 - номер наблюдения (v0<4 - это наблюдения 1,2,3)
Примеры: (a) v1=0 OR age>18 (б) gender='MALE' AND v4<>(v5+v6)
В случае совпадения имена переменных имеют больший приоритет, чем текстовые метки. Для задания текстовых меток используйте \$. Пример: "значение"\$.

OK

Отмена

Открыть...

Сохранить как...

Как видно из таблиц средние всех показателей и разбросы в большей, или меньшей степени отличаются. Ответ, можем ли это отличие распространить на генеральную совокупность стран мира, можно получить только применив методы сравнения средних

Следует обратить внимание, что разбросы первых 3 показателей можно сравнить при помощи стандартного отклонения, а вот, если добавить переменную другой единицы измерения 2000г, то для сравнения уже следует воспользоваться коэффициентом вариации

Переменная	Описательные статистики (Страны мира ¹)Условие включения: $v5=0$					
	Среднее	Медиана	Минимум	Максим.	Ст.откл.	Козф. Вар.
Пром.	33,6667	34,5000	27,00000	38,000	4,6762	13,8896
С/х	8,5000	2,0000	2,00000	29,000	11,1310	130,9534
Услуги	57,8333	60,0000	41,00000	71,000	11,0529	19,1116
2000г	252,6667	104,0000	59,00000	1010,000	373,3093	147,7478

Переменная	Описательные статистики (Страны мира ¹)Условие включения: $v5=1$					
	Среднее	Медиана	Минимум	Максим.	Ст.откл.	Козф. Вар.
Пром.	38,5000	40,0000	26,0000	48,000	9,2916	24,1340
С/х	11,7500	12,0000	2,0000	21,000	8,7702	74,6401
Услуги	49,7500	48,0000	31,0000	72,000	17,8022	35,7832
2000г	471,5000	232,5000	146,0000	1275,000	537,4064	113,9780



Корреляция

Между переменными (случайными величинами) может существовать функциональная связь, проявляющаяся в том, что одна из них определяется как функция от другой. Но между переменными может существовать и связь другого рода, проявляющаяся в том, что одна из них реагирует на изменение другой изменением своего закона распределения. Такую связь называют стохастической. Она появляется в том случае, когда имеются общие случайные факторы, влияющие на обе переменные.

В качестве меры зависимости между нормально распределенными переменными используется коэффициент корреляции Пирсона (r), который изменяется в пределах от -1 до $+1$. Если коэффициент корреляции отрицательный, это означает, что с увеличением значений одной переменной значения другой убывают.

- Если переменные независимы, то коэффициент корреляции равен 0 (обратное утверждение верно только для переменных, имеющих нормальное распределение).
- Но если коэффициент корреляции не равен 0 (переменные называются коррелированными), то это значит, что между переменными существует зависимость. Чем ближе значение r к 1, тем зависимость сильнее. Коэффициент корреляции характеризует **силу и направление линейной связи**, поэтому достигает своих предельных значений +1 или -1, тогда и только тогда, когда зависимость между переменными линейная. В модуле **Descriptive statistics** вычисляется коэффициент корреляции Пирсона, в предположении, что переменные измерены, как минимум, в интервальной шкале. Некоторые другие коэффициенты корреляции (например, корреляция Спирмена или тау Кендалла) могут быть вычислены для более слабых шкал и характеризуют **силу и направление монотонной взаимосвязи**!
- Принято считать, что при $|r| \leq 0,25$ – корреляция слабая, $0,25 < |r| \leq 0,75$ – умеренная, при $|r| \geq 0,75$ – сильная [12]. Сильная корреляция означает, что связь между переменными может быть близкой к линейной, но может быть явно нелинейной.

- Для построения корреляционной матрицы в верхнем меню **Statistics** надо выбрать команду **Basic Statistic Tables**, откроется меню команды. После выбора команды **Correlation Matrices** откроется рабочее окно модуля. Имена переменных можно задать одним списком (кнопка **One variables list**) или двумя списками (кнопка **Two lists**).
- В первом случае будет построена квадратная корреляционная матрица, строки и столбцы которой представлены списком переменных. Элементы матрицы – коэффициенты корреляции между переменными, расположенными на пересечении строки и столбца.
- Во втором случае будет построена прямоугольная матрица, строки и столбцы которой представлены соответственно первым и вторым списком .



Если нажать на кнопку **Матрица парных корреляций**
(в английской версии 10 и русскоязычной версии 13)


Нулевая гипотеза: коэффициент корреляции = 0

Variable	Correlations (Страны мира) Marked correlations are N=10 (Casewise deletion)		
	Пром.	С/х	Услуги
Пром.	1,00	0,34	-0,74
С/х	0,34	1,00	-0,88
Услуги	-0,74	-0,88	1,00

Переменная	Корреляции (Страны мира) Отмеченные корреляции значимы на уровне $p < ,05000$ N=10 (Построчное удаление ПД)				
	Средние	Ст.откл.	Пром.	С/х	Услуги
Пром.	35,60000	6,86699	1,000000	0,343179	-0,741934
С/х	9,80000	9,86351	0,343179	1,000000	-0,884371
Услуги	54,60000	13,81786	-0,741934	-0,884371	1,000000

Если нажать на кнопку **Матричная диаграмма рассеяния**, то появится график на котором будут изображены парные диаграммы всех со всеми и гистограммы

Корреляции (Страны мира1 9v*10с)



Если нажать на кнопку Графики, то появится 3 диаграммы рассеяний с доверительными интервалами на 3 отдельных графиках




Диаграмма рассеяния: Пром. vs. Услуги (Построч.удаление ПД)

$$\text{Услуги} = 107,75 - 1,493 * \text{Пром.}$$

Корреляция: $r = -,7419$






Диаграмма рассеяния: C/x vs. Услуги (Построч.удаление ПД)

$$\text{Услуги} = 66,741 - 1,239 * \text{C/x}$$


Корреляция: $r = -,8844$



На вкладке **Дополнительно** можно провести еще более детализированный корреляционный анализ, например матрицы корреляции в виде матричных файлов с расширением *mtx*, вычислить частные корреляции, построить трехмерные графики и т.д.



Если перейти на вкладку Опции, то можно в таблицу отобразить уровни значимости коэффициентов корреляции, построить более подробную таблицу результатов со средними значениями, стандартными отклонениями и т.д., также можно произвести вычисления с повышенной точностью



Переменная	Корреляции (Страны мира) Отмеченные корреляции значимы на уровне $p < ,05000$ N=10 (Построчное удаление ПД)		
	Пром.	С/х	Услуги
Пром.	1,0000	0,3432	-0,7419
	$p=---$	$p=0,332$	$p=0,014$
С/х	0,3432	1,0000	-0,8844
	$p=,332$	$p=---$	$p=,001$
Услуги	-0,7419	-0,8844	1,0000
	$P=0,014$	$p=0,001$	$p=---$

Если перейти на вкладку Карты цветов, то можно построить таблицу корреляций в абсолютных величинах, или построить карту цветов, на которой разными цветами будут изображены отрицательные, положительные, нулевые корреляции. Разными оттенками цветов будут изображены силы корреляционных связей

